

ỦY BAN NHÂN DÂN THÀNH PHỐ HỒ CHÍ MINH



TRƯỜNG ĐẠI HỌC SÀI GÒN
KHOA TOÁN – ỨNG DỤNG

BÁO CÁO BÀI THỰC HÀNH

Môn: Học sâu (Deep Learning)

Lab02: Dự báo giá nhà (House Prices)

STT	Họ và tên	MSSV
1	Đinh Quang Minh	3123580024
2	Dương Tấn Cường	3123580004
3	Lê Thành Duy	3123580007

Lớp: DDU1231
Ngành: Khoa học dữ liệu
Giảng viên hướng dẫn: TS. Đỗ Như Tài
Học kỳ: Học kỳ I, năm học 2026

TP. Hồ Chí Minh, tháng 9 năm 2026

Bảng phân công nhiệm vụ

STT	Họ và tên	Nội dung thực hiện	Đóng góp
1	Đinh Quang Minh	EDA, pipeline xử lý dữ liệu, mô hình tuyến tính (M0-M3), tổng hợp notebook	40%
2	Dương Tấn Cường	Mạng nơ-ron MLP, embeddings (M4-M6), fine-tune	30%
3	Lê Thành Duy	Ensemble, nộp Kaggle, vòng lặp cải tiến, viết báo cáo	30%

Mục lục

1	Giới thiệu bài toán	4
1.1	Mục tiêu	4
1.2	Metric đánh giá: RMSLE	4
1.3	Ràng buộc và tiêu chí thành công	4
2	Khám phá dữ liệu (EDA)	5
2.1	Phân phối giá và ô trống	5
2.2	Tương quan, khu vực và ngoại lệ	5
2.3	Kiểm tra độ lệch train/test	7
3	Chuẩn bị dữ liệu (pipeline dùng chung)	8
4	Mô hình và fine-tune (M0–M6)	9
5	Ensemble và nộp bài	10
5.1	Chọn đội hình và trộn mô hình	10
5.2	Phân tích residual	10
5.3	5 lần nộp và bài học overfit	10
6	Vòng lặp cải tiến	12
7	Kết luận	13

1 Giới thiệu bài toán

1.1 Mục tiêu

Cuộc thi Kaggle *House Prices – Advanced Regression Techniques* yêu cầu dự báo giá bán (**SalePrice**, USD) của 1459 căn nhà ở Ames, Iowa (tập test không nhãn), học từ 1460 căn có nhãn (tập train). Đây là bài toán **hồi quy có giám sát** dựa trên bộ dữ liệu nhà đất Ames do De Cock (2011) giới thiệu, gồm 79 biến giải thích: 23 nominal, 23 ordinal, 14 discrete và 20 continuous, mô tả chất lượng và số lượng của căn nhà.

1.2 Metric đánh giá: RMSLE

Kaggle chấm bằng **RMSLE** (sai số log quân phương):

$$\text{RMSLE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\log(1 + \hat{y}_i) - \log(1 + y_i))^2}.$$

RMSLE phạt sai số *tương đối*: đoán lệch 10 nghìn USD trên nhà rẻ bị phạt nặng hơn cùng mức lệch trên nhà đắt. Hệ quả thiết kế xuyên suốt bài làm: mọi huấn luyện, đánh giá và trộn mô hình đều thực hiện trên thang $\log(1 + y)$.


1.3 Ràng buộc và tiêu chí thành công

- Toàn bộ mô hình cài đặt bằng **PyTorch** (sklearn chỉ hỗ trợ chia fold và tiền xử lý).
- Quy trình theo 6 bước **CRISP-DM**, mỗi mô hình fine-tune 2 vòng (screening nhanh rồi refine bằng 5-fold CV), mọi thí nghiệm ghi vào nhật ký.
- Thành công nội bộ: CV-RMSLE giảm dần qua các thí nghiệm; minh chứng triển khai: điểm public leaderboard khi nộp Kaggle.

2 Khám phá dữ liệu (EDA)



2.1 Phân phối giá và ô trống


Giá bán lệch phải mạnh (skew 1.883, trung bình 181k > trung vị 163k); sau `log1p` skew chỉ còn 0.121, gần chuẩn — xác nhận quyết định làm việc trên thang log. Trong 81 cột có 19 cột thiếu, nhưng thiếu đều có ý nghĩa: PoolQC (99.5%), MiscFeature (96%), Alley (94%), Fence (81%) thiếu nghĩa là *không có* hạng mục đó, nên điền 'Missing' thay vì xóa.



2.2 Tương quan, khu vực và ngoại lệ

Các biến đắt giá nhất: OverallQual (0.817), GrLivArea (0.701), GarageCars (0.681) — đúng như paper nhấn mạnh. Heatmap cho thấy cụm Garage, cụm diện tích và OverallQual dính chùm với nhau: đa cộng tuyến rõ, báo trước cần regularization. Hiệu ứng vị trí rất mạnh: trung vị khu NridgHt (315k) gấp gần 3 lần khu MeadowV (88k). Có 4 căn **GrLivArea** > 4000 sqft (paper báo 5 trên toàn bộ dữ liệu), gồm 2 căn to nhưng rẻ bất thường — loại khỏi train theo khuyến nghị.





2.3 Kiểm tra độ lệch train/test

Kiểm định KS trên các cột trụ cho p-value 0.08–0.99 (đều > 0.05), chênh tỉ lệ khu vực tối đa 0.023, adversarial AUC 0.34 (phân biệt train/test không tốt hơn ngẫu nhiên). Kết luận: không có shift dữ liệu, cross-validation trên train đáng tin để chọn mô hình.

3 Chuẩn bị dữ liệu (pipeline dùng chung)

Pipeline viết tường minh từng bước bằng pandas (không dùng khối hộp đen), áp dụng giống nhau cho mọi mô hình; fit chỉ trên train rồi transform test để tránh rò rỉ:

1. **Bỏ ngoại lệ + tách target:** loại 4 căn `GrLivArea > 4000`, train còn 1456 dòng; target $y_{\log} = \log(1 + \text{SalePrice})$.
2. **Điền ô trống:** cột số điền trung vị (bền với ngoại lệ, test dùng trung vị của train); cột chữ điền 'Missing'.
3. **Log cột lệch:** 19 cột số có skew > 0.75 (ví dụ `LotArea 12.59`) được `log1p` sau khi chặn âm về 0.
4. **One-hot:** 43 cột chữ thành 266 cột 0/1 (mức xếp A–Z cố định từ train, mức lạ ở test thành toàn 0); riêng `Neighborhood` 25 mức.
5. **Chuẩn hóa + chia fold:** cột số về trung bình 0, độ lệch 1; ma trận cuối 1456×302 ; 5-fold chung (seed 42) lưu sẵn để mọi mô hình thi cùng đề.
6. **Kiểm tra shift:** adversarial AUC 0.34 — train/test đồng nhất.

Rủi ro đã biết từ bước này: 302 chiều trên 1456 dòng dễ overfit với hồi quy thường — đây chính là lý do GD2 cần Ridge/Lasso/Dropout.

4 Mô hình và fine-tune (M0–M6)

Mọi mô hình cài bằng PyTorch, cùng 5-fold seed 42, metric RMSLE thang log; mỗi mô hình trải 2 vòng (screening nhanh rồi refine) và ghi nhật ký. Kết quả vòng chính:

Mô hình	Cấu hình tốt nhất	CV-RMSLE
M0 baseline	Đoán trung vị chung	0.3970
M1b OLS top-20	Chỉ 20 biến số mạnh nhất	0.1356
M1 OLS full	Nghiem đồng, 302 đặc trưng	0.1283
M2 Ridge	Phạt L2, $\lambda = 10$	0.1119
M3 ElasticNet	$\alpha = 0.2$, $\lambda = 10^{-5}$	0.1239
M4 MLP 1 tầng	64 nút, lr= 3×10^{-3} , không dropout	0.1252
M5 MLP sâu	128×128, không BatchNorm	0.1411
M6 Embeddings	Vector riêng mỗi mức phân loại	0.1348

Ba bài học rút ra:


- **M1 full (0.1283) thắng M1b top-20 (0.1356):** không lọc cứng theo tương quan — để Ridge/Lasso tự chọn biến một cách có nguyên tắc.
- **M5 thua M4, BatchNorm thảm họa (0.44–0.49):** với chỉ 1456 dòng, thêm tầng thành overfit; full-batch nhỏ làm thống kê BatchNorm thành rác ở chế độ đánh giá.
- **M6 cần dữ liệu lớn:** embedding khởi tạo $N(0,1)$ làm loss nổ (phải thu $\times 0.1$), weight-decay kéo cả bảng về 0; cần 6000 epoch mới hội tụ.

Kết luận GD2: bài toán gần tuyến tính + dữ liệu nhỏ nên Ridge thắng; MLP/embeddings giữ lại lấy tính đa dạng cho ensemble.

5 Ensemble và nộp bài

5.1 Chọn đội hình và trộn mô hình

Đội hình ensemble gồm 4 mô hình vừa mạnh vừa khác kiểu nhau: Ridge-10, ElasticNet, M4 và M6. Trọng số trộn được tune bằng grid 286 bộ trên dữ liệu out-of-fold (tuyệt đối không chạm test). Kết quả M7: Ridge 0.9 + M6 0.1 (Enet/M4 trọng số 0 vì dự báo tương quan cao với Ridge) — OOF 0.11140, hơn Ridge đơn 0.11193.



5.2 Phân tích residual

Trên thang USD: mọi mô hình bias âm nhẹ (đoán thấp hơn thật 1–4k), MAE 13.5–15.7k, sai số lớn nhất rơi vào nhà đất tiền (161–260k) — đúng bản chất RMSLE nhẹ tay với nhà đất.

5.3 5 lần nộp và bài học overfit

Lần	File (mô hình)	OOF	LB
1	submission.csv (M7)	0.11140	0.12581
2	submission_v2.csv (giống hết lần 1)	0.11140	0.12581
3	submission_v3.csv (M7c + MLP/đặc trưng mới)	0.11128	0.12805
4	submission_v4.csv (M7d + Ridge phạt mạnh)	0.11103	0.12679
5	submission_v5.csv (giống hết lần 4)	0.11103	0.12679

OOF cứ nhích xuống từng chút nhưng LB loang quanh 0.126–0.128, không vượt nổi lần 1: các cải thiện 0.000x ở nhà chỉ là nhiễu, mô hình đã chạm trần của cách làm hiện tại. Chênh lệch CV–LB khoảng 0.014 cho thấy overfit nhẹ — đúng bệnh để các vòng lặp sau chữa.

6 Vòng lặp cải tiến

Sau lần nộp đầu (LB 0.12581), nhóm lặp đúng 1 cải tiến mỗi vòng, dừng khi 2 vòng liên tiếp không tiến bộ:

- **Vòng 2 — thêm 6 đặc trưng (TotalSF, tuổi nhà, QualArea...) + Ridge: thất bại.** Ridge mới (0.11201) thua Ridge cũ (0.11193): TotalSF chỉ là cộng 2 cột cũ lại (tuyến tính tự cộng được), QualArea là phép nhân mà đường thẳng không hiểu. Trộn ra 100% cũ + 0% mới nên **không nộp**.
- **Vòng 3 — MLP + đặc trưng mới: thắng.** M4b đạt 0.12397 (hơn M4 cũ 0.12520): mạng nơ-ron ăn được phép nhân QualArea. Trộn M7c (0.11128) và nộp lần 3, nhưng LB 0.12805 không theo — cải thiện OOF quá nhỏ, chỉ là nhiễu.
- **Vòng 4 — Ridge phạt mạnh ($\lambda = 30$): thắng nửa vời.** Một mình chỉ 0.11222 nhưng sai khác hướng với M7 nên trộn M7d đạt 0.11103 — bài học: thành viên ensemble không cần giỏi hơn, chỉ cần sai khác nhau. LB lần 4: 0.12679.
- **Vòng 5 — seed-ensemble M4: nửa thắng nửa thua.** Trung bình 3 seed đạt 0.12291 (hơn M4 đơn) nhưng trộn vào M7d vẫn 100% cũ + 0% mới. **Dừng vòng lặp**, nộp lại M7d làm lần 5 cho hoàn thiện (LB 0.12679).

Bài học lớn nhất: đặc trưng mới chỉ phát huy khi gặp đúng mô hình, và săn từng 0.000x trên CV rất dễ tự lừa mình — phải để LB thật phán xử.

7 Kết luận

Nhóm đã hoàn thành bài toán dự báo giá nhà theo đúng 6 bước CRISP-DM, toàn bộ mô hình bằng PyTorch: EDA phát hiện giá lệch phải và đa cộng tuyến; pipeline 6 bước cho ra ma trận 1456×302 ; fine-tune 2 vòng trên 8 họ mô hình (70 thí nghiệm có nhật ký); ensemble M7 (Ridge 0.9 + M6 0.1) đạt CV 0.11140 và **LB public 0.12581** sau 5 lần nộp.

Hạn chế: chênh CV–LB khoảng 0.014 (overfit nhẹ); dữ liệu chỉ 1456 dòng nên mạng sâu và embeddings chưa phát huy hết; 4/6 đặc trưng mới không thêm thông tin cho mô hình tuyến tính. Hướng tiếp theo: stacking có meta-learner, mã hóa thứ tự cho biến ordinal, và thử gradient boosting làm thành viên ensemble ngoài PyTorch để đối chứng.